



PONTIFICIA
UNIVERSIDAD
CATÓLICA
DEL PERÚ


SEMINARIO DE TESIS II

20166405 Gary Velásquez Narro

Título propuesto de la tesis


- ▶ Evaluación de la generación de datos sintéticos para la creación de modelos de recomendación de técnicas de selección de atributos para conjuntos de datos de expresión génica.

DNA




transcription

mRNA




translation

Protein




mRNA



microarray chip

Con la tecnología de microarray se “imprimen” las secuencias biológicas en un chip




000015700001
...
000000310100
...
0000000004000
0000000001000
0000000004000
0000000000003
0000000000000
...

De manera que podemos cuantificar el nivel de transcripción en una matriz numérica

Matriz de expresión

conditions
 h_1 h_2 d_1 d_2



genes

10^3 genes

10^{1-2} conditions

Una matriz de expresión tiene un tamaño considerable → necesidad de métodos informáticos para su análisis

Problemática

- ▶ Una de las promesas de la bioinformática y la genómica es poder identificar tempranamente la presencia de patologías, tales como el cáncer, a partir del perfil de expresión génica de la persona.
- ▶ La dimensionalidad de los datos de expresión génica es muy alta, es decir, las muestras están en el orden de las centenas mientras que atributos en el orden de los millares.
- ▶ Meta aprendizaje ha sido propuesta para aprender a partir de la acumulación de experiencias para ayudar a sugerir el mejor método de aprendizaje de máquina para un conjunto de datos dado.
- ▶ Sin embargo, se ha identificado también que existen limita cantidad de conjuntos de datos de expresión génica para ser viable el proceso de meta aprendizaje.
- ▶ La presente investigación propone elaborar una metodología de generación de datos sintéticos de expresión génica, generados en base al conjunto de datos reales; para ser usados en el proceso de meta aprendizaje y poder verificar si la incorporación de estos nuevos conjuntos de datos mejoran la precisión del modelo.

Objetivos de la investigación

► General:

- ❑ Elaborar y evaluar una metodología de generación de datos sintéticos de expresiones génicas en el contexto de meta aprendizaje para ser usados en la sugerencia de métodos de reducción dimensional.

► Específicos:

- ❑ Organizar un corpus de conjuntos de datos de expresión génica de diversas patologías humanas..
- ❑ Implementar un modelo de meta aprendizaje sobre el corpus resultante. Extracción de la meta data: meta atributos y desempeños de técnicas de aprendizaje de máquina, elaboración esquema de reducción dimensional.
- ❑ Diseñar el esquema de generación de datos de expresión génicas sintéticas de dos maneras.

Perturbación de Datos: Usando un algoritmo que hace modificaciones de los datos originales.(Explorar los puntos desconocidos)

- ❑ Evaluar numéricamente la precisión del modelo de meta aprendizaje implementado en el paso 2. Se buscará verificar si la adición de datos de expresión génica sintéticos a los datos reales, ayuda al modelo a tener un mejor rendimiento en su tarea de sugerir los mejores métodos de reducción dimensional.

Cronograma

[illegible]

Avances

- ▶ Recolección de corpus de conjuntos de datos expresión génica de
- ▶ Recopilación de generadores de datos de expresión génica sintética.
- ▶ Generación de matriz de meta aprendizaje: Meta atributos y predictores.
- ▶ Implementación del modelo de meta aprendizaje(k-Nearest Neighbors Ranking Method).

Desarrollo y Experimentación

- Corpus con 60 base de datos de perfiles de expresión génica

Data

	1 X																		
	F_1	F_2	F_3	F_4	F_5	F_6	F_7	F_8	F_9	F_10	...	F_1991	F_1992	F_1993	F_1994	F_1995	F_1996	F_1997	F_199
V1	754.0	315.0	5986.0	3095.0	3733.0	636.0	2517.0	2931.0	2174.0	2455.0	...	23.0	23.0	-23.0	27.0	-34.0	33.0	27.0	25.0
V2	218.0	71.0	2422.0	2002.0	1542.0	400.0	1658.0	1702.0	1521.0	1605.0	...	14.0	46.0	-8.0	18.0	-18.0	72.0	25.0	10.0
V3	3049.0	2500.0	8839.0	3994.0	4711.0	120.0	3823.0	2630.0	3746.0	2185.0	...	28.0	10.0	-52.0	60.0	-8.0	36.0	44.0	9.0
V4	2718.0	2478.0	6106.0	2581.0	2583.0	1688.0	2404.0	1668.0	2361.0	1282.0	...	34.0	14.0	-31.0	60.0	-20.0	41.0	50.0	46.0
V5	840.0	426.0	3380.0	1590.0	2020.0	491.0	2046.0	1951.0	1959.0	1813.0	...	23.0	66.0	-5.0	26.0	7.0	31.0	18.0	37.0
V6	1833.0	1467.0	5221.0	1379.0	2926.0	128.0	3401.0	2136.0	3308.0	1831.0	...	14.0	14.0	-26.0	42.0	-26.0	24.0	23.0	20.0
V7	1903.0	1463.0	5005.0	2670.0	3160.0	1402.0	1928.0	2236.0	2244.0	1764.0	...	53.0	28.0	-37.0	50.0	4.0	71.0	42.0	36.0
V8	159.0	50.0	1685.0	1243.0	1401.0	471.0	1280.0	1273.0	1214.0	1280.0	...	11.0	60.0	2.0	18.0	-24.0	14.0	4.0	18.0
V9	2941.0	1880.0	9678.0	4297.0	2974.0	1311.0	3575.0	23.0	1847.0	18.0	...	24.0	12.0	-31.0	50.0	43.0	39.0	58.0	90.0
V10	3148.0	2056.0	8473.0	3936.0	4097.0	1328.0	3424.0	387.0	2888.0	224.0	...	92.0	6.0	-45.0	44.0	12.0	71.0	62.0	44.0
V11	751.0	397.0	3715.0	2247.0	2097.0	1152.0	2278.0	2043.0	1757.0	2104.0	...	18.0	48.0	-15.0	22.0	-15.0	33.0	76.0	31.0
V12	4396.0	3168.0	9044.0	3291.0	2943.0	276.0	4279.0	586.0	3233.0	341.0	...	78.0	12.0	-9.0	115.0	-10.0	107.0	65.0	28.0
V13	896.0	481.0	3229.0	2492.0	1930.0	1399.0	2461.0	2658.0	2000.0	2518.0	...	26.0	68.0	-12.0	33.0	-23.0	32.0	54.0	41.0
V14	6144.0	5292.0	8397.0	2978.0	2650.0	54.0	3050.0	192.0	3259.0	136.0	...	79.0	6.0	-77.0	162.0	-90.0	162.0	77.0	16.0

Target

```
In [339]: 1 Y
Out[339]: V1      0.0
           V2      0.0
           V3      0.0
           V4      0.0
           V5      0.0
           V6      0.0
           V7      0.0
           V8      0.0
           V9      0.0
           V10     0.0
           V11     0.0
           V12     0.0
           V13     0.0
           V14     0.0
           V15     0.0
           V16     0.0
           V17     0.0
           V18     0.0
           V19     0.0
           V20     0.0
           V21     0.0
           V22     0.0
           V23     0.0
           V24     0.0
           V25     0.0
           V26     0.0
           V27     0.0
           V28     0.0
           V29     0.0
           V30     0.0
           ...
           V73     1.0
           V74     1.0
           V75     1.0
           V76     1.0
           V77     1.0
```


Desarrollo y Experimentación

- Corpus con 60 base de datos de perfiles de expresión génica

Data

	1 X																		
	F_1	F_2	F_3	F_4	F_5	F_6	F_7	F_8	F_9	F_10	...	F_1991	F_1992	F_1993	F_1994	F_1995	F_1996	F_1997	F_199
V1	754.0	315.0	5986.0	3095.0	3733.0	636.0	2517.0	2931.0	2174.0	2455.0	...	23.0	23.0	-23.0	27.0	-34.0	33.0	27.0	25.0
V2	218.0	71.0	2422.0	2002.0	1542.0	400.0	1658.0	1702.0	1521.0	1605.0	...	14.0	46.0	-8.0	18.0	-18.0	72.0	25.0	10.0
V3	3049.0	2500.0	8839.0	3994.0	4711.0	120.0	3823.0	2630.0	3746.0	2185.0	...	28.0	10.0	-52.0	60.0	-8.0	36.0	44.0	9.0
V4	2718.0	2478.0	6106.0	2581.0	2583.0	1688.0	2404.0	1668.0	2361.0	1282.0	...	34.0	14.0	-31.0	60.0	-20.0	41.0	50.0	46.0
V5	840.0	426.0	3380.0	1590.0	2020.0	491.0	2046.0	1951.0	1959.0	1813.0	...	23.0	66.0	-5.0	26.0	7.0	31.0	18.0	37.0
V6	1833.0	1467.0	5221.0	1379.0	2926.0	128.0	3401.0	2136.0	3308.0	1831.0	...	14.0	14.0	-26.0	42.0	-26.0	24.0	23.0	20.0
V7	1903.0	1463.0	5005.0	2670.0	3160.0	1402.0	1928.0	2236.0	2244.0	1764.0	...	53.0	28.0	-37.0	50.0	4.0	71.0	42.0	36.0
V8	159.0	50.0	1685.0	1243.0	1401.0	471.0	1280.0	1273.0	1214.0	1280.0	...	11.0	60.0	2.0	18.0	-24.0	14.0	4.0	18.0
V9	2941.0	1880.0	9678.0	4297.0	2974.0	1311.0	3575.0	23.0	1847.0	18.0	...	24.0	12.0	-31.0	50.0	43.0	39.0	58.0	90.0
V10	3148.0	2056.0	8473.0	3936.0	4097.0	1328.0	3424.0	387.0	2888.0	224.0	...	92.0	6.0	-45.0	44.0	12.0	71.0	62.0	44.0
V11	751.0	397.0	3715.0	2247.0	2097.0	1152.0	2278.0	2043.0	1757.0	2104.0	...	18.0	48.0	-15.0	22.0	-15.0	33.0	76.0	31.0
V12	4396.0	3168.0	9044.0	3291.0	2943.0	276.0	4279.0	586.0	3233.0	341.0	...	78.0	12.0	-9.0	115.0	-10.0	107.0	65.0	28.0
V13	896.0	481.0	3229.0	2492.0	1930.0	1399.0	2461.0	2658.0	2000.0	2518.0	...	26.0	68.0	-12.0	33.0	-23.0	32.0	54.0	41.0
V14	6144.0	5292.0	8397.0	2978.0	2650.0	54.0	3050.0	192.0	3259.0	136.0	...	79.0	6.0	-77.0	162.0	-90.0	162.0	77.0	16.0

Target

```
In [339]: 1 Y
Out[339]: V1      0.0
           V2      0.0
           V3      0.0
           V4      0.0
           V5      0.0
           V6      0.0
           V7      0.0
           V8      0.0
           V9      0.0
           V10     0.0
           V11     0.0
           V12     0.0
           V13     0.0
           V14     0.0
           V15     0.0
           V16     0.0
           V17     0.0
           V18     0.0
           V19     0.0
           V20     0.0
           V21     0.0
           V22     0.0
           V23     0.0
           V24     0.0
           V25     0.0
           V26     0.0
           V27     0.0
           V28     0.0
           V29     0.0
           V30     0.0
           ...
           V73     1.0
           V74     1.0
           V75     1.0
           V76     1.0
           V77     1.0
```

Desarrollo y Experimentación


Selección de Métodos de Selección de Características

Filter methods:

- ▶ F regression
- ▶ ANOVA
- ▶ chi-square test
- ▶ variance threshold

Embedded methods:

- ▶ Recursive feature elimination
- ▶ L1 (LASSO) regularization



Desarrollo y Experimentación


Selección de Algoritmos de Clasificación

Matriz: FSM+Classifier

- ▶ KNeighbors
- ▶ Multi Layer Perceptron(MLP)
- ▶ Logistic Regression
- ▶ SVN
- ▶ Naive Bayes
- ▶ Decision tree
- ▶ Random Forest
- ▶ AdaBoost

F_Regression - DecitionTree	ANOVA - DecitionTree	Chi2 - DecitionTree	Threshold - DecitionTree	RFE - DecitionTree	L1 - DecitionTree
F_Regression - KNeighbors	ANOVA - KNeighbors	Chi2 - KNeighbors	Threshold - KNeighbors	RFE - KNeighbors	L1 - KNeighbors
F_Regression - Perceptron	ANOVA - Perceptron	Chi2 - Perceptron	Threshold - Perceptron	RFE - Perceptron	L1 - Perceptron
F_Regression - LogicticRegresion	ANOVA - LogicticRegresio n	Chi2 - LogicticRegresio n	Threshold - LogicticRegresion	RFE - LogicticRegresio n	L1 - LogicticRegresion
F_Regression - SVN	ANOVA - SVN	Chi2 - SVN	Threshold - SVN	RFE - SVN	L1 - SVN
F_Regression - NaiveBayes	ANOVA - NaiveBayes	Chi2 - NaiveBayes	Threshold - NaiveBayes	RFE - NaiveBayes	L1 - NaiveBayes
F_Regression - RandomForest	ANOVA - RandomForest	Chi2 - RandomForest	Threshold - RandomForest	RFE - RandomForest	L1 - RandomForest
F_Regression - AdaBoost	ANOVA - AdaBoost	Chi2 - AdaBoost	Threshold - AdaBoost	RFE - AdaBoost	L1 - AdaBoost

Arquitectura del Modelo de Meta Aprendizaje





Procedimientos

Calculo par: FSM+Classifier

Chi2-SVM

Ranking AUC

Receiver operating characteristic(ROC) - dataset_prostate_singh



Matriz Meta Atributos

Información estadística de los datasets: n = 40

Out[8]:

	dataset	X_correlation_max	X_correlation_mean	X_correlation_min	X_covariance_max	X_covariance_mean	X_covariance_min	X_exp
0	dataset_prostate_singh	0.994905358	0.00136795	-0.989839618	6501920,592	29,65437555	-1662059,024	0,5
1	dataset_glioma_phillips	0.993588786	0.026852548	-0.690733041	432343466,2	245013,5022	-65924954,33	0,3
2	dataset_leukemia_armstrong	0.994279811	0.084879388	-0.916524345	115480599,7	556524,6375	-73486293,94	0,2
3	dataset_breast_sotiriou	0.997309506	0.703430742	-0.803857705	6,24486413	1,45107964	-5,063628483	0,7
4	dataset_lymphoma_dave_2	0.985846957	0.019387122	-0.739593891	5,893251503	0,027502559	-3,396945392	0,1
5	dataset_liver_iizuka	0.987922971	0.003358949	-0.881592705	77481050,23	13854,60989	-12801761,19	0,3
6	dataset_srbct_khan	0.972496784	0.009346824	-0.681342502	20,02175108	-7,58E-05	-3,189687321	0,1
7	dataset_lung_beer	0.997511943	0.00310986	-0.923347041	147739283	915,624243	-50965738,01	0,1
8	dataset_breast_west	0.995588405	0.00461948	-0.996293484	7978510752	93190,36612	-2596910070	0,6
9	dataset_mixed_monti	0.998537045	0.004454326	-0.797925948	81439739,58	4427,306021	-23639178,61	0,4
10	dataset_bladder_sanchez-carbayo	0.998970629	0.024284299	-0.775310125	2772741306	1090140,983	-338101581	0,3
11	dataset_leukemia_haslinger	0.995720969	0.005888104	-0.797096832	15699566293	8092599,575	-1384869355	0,7
12	dataset_cns_pomeroy_2	0.990873531	0.131770305	-0.980951759	593333981,5	149404,4397	-266666796,8	0,3
13	dataset_breast_glaab	0.986115637	0.017303344	-0.794021929	5,499599968	0,009521221	-1,496606411	0,1
14	dataset_breast_veer	0.995935773	0.016819117	-0.821562945	0,551761989	0,004192316	-0,316786585	0,0
15	dataset_breast_perou	0.984723468	0.034871603	-0.808569015	3,879855762	0,039399342	-2,810440925	0,0
16	dataset_mixed_ramaswamy	0.997581588	0.109544134	-0.986307293	201387491,4	216123,643	-118872168,9	0,2
17	dataset_leukemia_golub	0.992774116	0.076344779	-0.995410036	138408172	56916,73021	-33108553,63	0,1
18	dataset_breast_wang	0.996786002	0.012360188	-0.666807888	555082878,5	490731,4744	-101539050,5	0,2


Matriz de Desempeños

Rankings

	dataset	F_test- NaiveBayes	F_test- Kneighbors	F_test- LogisticRegresion	F_test- SVN	F_test- DecitionTree	F_test- RandomForest	I1- NaiveBayes	I1- KNeighbors	I1- LogicticRegresic
0	dataset_prostate_singh	20.0	5.0	2.0	0.0	14.0	3.0	22.0	6.0	4
1	dataset_glioma_phillips	20.5	8.0	9.0	6.0	16.0	5.0	20.5	10.0	13
2	dataset_leukemia_armstrong	20.0	8.5	8.5	1.0	1.0	1.0	22.0	8.5	8
3	dataset_breast_sotiriou	17.5	6.0	4.0	0.0	15.0	5.0	17.5	14.0	10
4	dataset_lymphoma_dave_2	21.0	12.0	6.0	5.0	15.0	4.0	23.0	8.0	3
5	dataset_liver_iizuka	13.0	2.0	1.0	0.0	20.0	11.0	17.0	10.0	22
6	dataset_srbct_khan	21.5	6.0	7.0	2.0	11.0	0.5	21.5	17.0	9
7	dataset_lung_beer	19.0	1.5	3.0	0.0	5.0	1.5	19.0	10.0	17
8	dataset_breast_west	5.5	2.0	0.0	1.0	23.0	11.0	5.5	20.0	19
9	dataset_mixed_monti	21.0	12.0	16.0	3.5	10.5	1.0	22.0	6.0	8
10	dataset_bladder_sanchez-carbayo	21.0	10.0	2.0	4.0	19.0	11.0	21.0	12.5	2
11	dataset_leukemia_haslinger	21.0	8.0	2.0	4.0	15.0	19.0	21.0	11.5	2
12	dataset_cns_pomeroy_2	21.0	0.0	3.0	5.0	15.0	19.0	21.0	13.0	3

Evaluación de Modelo

DataSet reales




Getting the highest value among all the K's

```
1 matrix_acuracies.loc[matrix_acuracies['coef'].idxmax()]
```

```
k      45.000000  
coef    0.757669  
p      0.020770
```

Evaluación de Modelo

DataSet reales + Data Sintética



```
1 matrix_acuracies_synthetic.loc[matrix_acuracies_synthetic['coef'].idxmax()]
```

k	92.000000
coef	0.757814
p	0.021225

Evaluación de Modelo

Resumen de experimentación

	sigma	1r - 0 (no sigma)	0 - 1s	1r - 1s	1r - 2s	1r - 3s	0 - 2s
0	0.100	k=51; coef=0.758874	k=42; coef=0.758312	k=118; coef=0.758255	k=2; coef=0.868762	k=3; coef=0.913815	k=1; coef=1
1	0.010	k=51; coef=0.758874	k=50; coef=0.759170	k=70; coef=0.758694	k=10; coef=0.909123	k=12; coef=0.933081	k=1; coef=1
2	0.001	k=51; coef=0.758874	k=51; coef=0.758874	k=72; coef=0.758557	k=91; coef=0.917688	k=132; coef=0.937675	k=1; coef=1

GRACIAS